

Шпаргалка по ИИ и машинному обучению

Понятия и типы задач, порядок работы над моделью, разбиение данных, метрики качества, распространённые алгоритмы, основы нейросетей, типичные ошибки и словарь по языковым моделям.

Типы обучения

- **С учителем** — есть размеченные примеры: классификация (метка) и регрессия (число).
- **Без учителя** — разметки нет: кластеризация, снижение размерности, поиск аномалий.
- **С частичной разметкой** — размечена только часть данных.
- **С подкреплением** — агент учится действиями и получает награду.
- **Перенос обучения** — готовая модель дообучается под свою задачу; экономит данные и время.

Порядок работы

1. Сформулировать задачу
Что предсказываем, какое решение это изменит, какая точность достаточна
2. Собрать и изучить данные
Объём, пропуски, дубликаты, дисбаланс классов, источники смещения
3. Подготовить признаки
Очистка, кодирование категорий, масштабирование, создание новых признаков
4. Базовое решение
Простая модель или даже правило — точка отсчёта, без которой не видно прогресса
5. Обучение и подбор
Кросс-валидация, подбор гиперпараметров
6. Оценка
Метрики на отложенной выборке, разбор ошибок по группам данных
7. Внедрение и наблюдение
Мониторинг качества и дрейфа данных, регулярное переобучение

Разбиение данных

- Обучающая выборка
На ней модель настраивает параметры
- Проверочная (валидационная)
Для выбора модели и гиперпараметров
- Тестовая
Трогается один раз в самом конце — иначе оценка завышена
- Кросс-валидация по K блокам
Данные делятся на K частей, обучение повторяется K раз — устойчивее одной проверки
- Разбиение по времени
Для временных рядов: обучение на прошлом, проверка на будущем

Утечка данных — самая частая причина «слишком хороших» результатов: признак содержит сведения о будущем или масштабирование выполнено до разбиения выборок.

Метрики: классификация

- Accuracy (доля верных)
Бесполезна при сильном дисбалансе классов
- Precision (точность)
Какая доля предсказанных положительных верна — важна, когда дорога ложная тревога
- Recall (полнота)
Какую долю положительных нашли — важна, когда дорог пропуск
- F1
Среднее гармоническое точности и полноты
- ROC-AUC / PR-AUC
Качество ранжирования; при редком положительном классе информативнее PR-AUC
- Матрица ошибок
Таблица верных и ошибочных предсказаний по классам — смотрите её всегда

Метрики: регрессия

- MAE
Средняя абсолютная ошибка, устойчива к выбросам
- MSE / RMSE
Сильнее наказывает крупные ошибки; RMSE в единицах целевой величины
- MAPE
Ошибка в процентах; плохо работает при значениях около нуля
- R²
Доля объяснённой дисперсии: 1 — идеально, 0 — как предсказание средним

Классические алгоритмы

- **Линейная и логистическая регрессия** — быстрые, объяснимые, хорошая отправная точка.
- **Деревья решений** — понятные правила, но легко переобучаются.
- **Случайный лес** — ансамбль деревьев, устойчив и почти не требует настройки.
- **Градиентный бустинг** (XGBoost, LightGBM, CatBoost) — обычно лучший выбор для табличных данных.
- **K ближайших соседей** — прост, но медленный на больших данных.
- **Метод опорных векторов** — хорош на небольших выборках с чёткой границей.
- **K-средних** и **DBSCAN** — кластеризация; **PCA** и **UMAP** — снижение размерности.

Нейросети

Слой и нейрон

Линейное преобразование плюс нелинейная функция активации

Функция потерь

Мера ошибки: перекрёстная энтропия для классификации, среднеквадратичная для регрессии

Градиентный спуск

Обновление весов в сторону уменьшения потерь; Adam — популярный вариант

Скорость обучения

Слишком велика — расхождение, слишком мала — обучение тянется вечно

Эпоха и батч

Полный проход по данным; порция примеров за один шаг

Свёрточные сети

Изображения и сигналы

Рекуррентные сети и трансформеры

Последовательности; трансформеры вытеснили рекуррентные в большинстве задач

Регуляризация

Dropout, затухание весов, ранняя остановка, расширение данных

Недообучение и переобучение

Недообучение

Плохо и на обучении, и на проверке: модель слишком проста или признаков мало

Переобучение

Отлично на обучении, плохо на проверке: нужна регуляризация, больше данных или модель проще

Кривые обучения

Графики ошибки на обучении и проверке показывают, чего именно не хватает

Дисбаланс классов

Взвешивание классов, изменение порога, перевыборка; точность сама по себе обманчива

Языковые модели

- **Токен** — кусок текста, которым оперирует модель; счёт идёт в токенах, не в словах.
- **Контекстное окно** — сколько токенов модель видит за раз.
- **Температура** — разброс ответов: ниже — предсказуемее, выше — разнообразнее.
- **Промпт** — инструкция и данные; примеры в промпте часто дают больше, чем длинные объяснения.
- **RAG** — поиск по своим документам и подстановка найденного в промпт; лечит незнание свежих фактов.
- **Дообучение** — изменение весов под задачу или стиль; нужно реже, чем кажется.
- **Галлюцинация** — уверенно сформулированный неверный ответ; проверяйте факты и требуйте ссылок на источник.
- **Эмбединг** — числовое представление текста для поиска по смыслу и кластеризации.

Инструменты

- **pandas, NumPy** — подготовка и анализ данных.
- **scikit-learn** — классические алгоритмы, разбиения, метрики, конвейеры.
- **PyTorch, TensorFlow** — нейросети.
- **XGBoost, LightGBM, CatBoost** — бустинг для таблиц.
- **MLflow, Weights & Biases** — учёт экспериментов и версий моделей.
- **Jupyter** — исследование; рабочий код лучше выносить в обычные модули.

Что помнить

- Качество данных влияет на результат сильнее выбора алгоритма.
- Простая модель, которую понимают и сопровождают, часто полезнее сложной.
- Сравнивайте не с идеалом, а с базовым решением и с тем, как задача решается сейчас.
- Смещение в данных превращается в смещение в решениях: проверяйте качество по группам.
- Модель в эксплуатации устаревает: следите за дрейфом и планируйте переобучение.